

Дослідження моделі gptTTS на базі GPT-2 для синтезу мовлення

Вступ

У даній роботі досліджується модель синтезу мовлення gptTTS, побудована на основі архітектури GPT-2, яка використовується як каузальна мовна модель для генерації аудіо-токенів. Ключова ідея підходу полягає у представленні мовлення як послідовності дискретних одиниць, що дозволяє застосовувати методи мовного моделювання до задачі текст-у-мовлення. На відміну від класичних TTS-систем, модель не працює безпосередньо з безперервним сигналом, а оперує дискретними кодами, отриманими за допомогою нейронного кодека FocalCodec, що спрощує формулювання задачі як прогнозування послідовності.

Основною метою роботи було створення повноцінного тренувального пайплайну, дослідження впливу техніки Classifier-Free Guidance на якість генерації, а також проведення кількісної оцінки результатів із використанням сучасних метрик.

Дані та попередня обробка

Для навчання було використано датасет LJ Speech, що містить близько 13 тисяч аудіозаписів одного диктора загальною тривалістю приблизно 24 години. Така однорідність голосу дозволяє стабільно оцінювати якість синтезу без впливу міжспікерної варіативності.

Текстова складова оброблялася через фонетичну токенизацію: вхідний текст перетворювався у послідовність фонем за стандартом IPA із використанням бекенду espeak, після чого виконувалася нормалізація символів для зменшення варіативності представлення. Це рішення дозволило зменшити неоднозначність вимови та зробити навчання більш стабільним. Аудіо, у свою чергу, кодувалося у 8192 дискретних токенів за допомогою FocalCodec, що переводить задачу синтезу у площину дискретного моделювання.

Архітектура та процес навчання

Модель базується на спрощеній конфігурації GPT-2, яка включає шість трансформерних шарів, шість голів самоуваги та розмірність ембеддінгів 384. Така конфігурація є компромісом між обчислювальною ефективністю та здатністю моделі вивчати залежності у послідовностях аудіо-токенів.

Навчання було реалізовано за допомогою фреймворку PyTorch Lightning, що дозволило структурувати код та спростити керування експериментами. Для оптимізації використовувався алгоритм AdamW із ваговим розпадом, а динаміка навчання контролювалася за допомогою Cosine Annealing scheduler із фазою розігріву. Валідація здійснювалася через моніторинг функції втрат із застосуванням ранньої зупинки та збереження найкращих моделей.

Classifier-Free Guidance

У роботі було досліджено застосування техніки Classifier-Free Guidance, яка дозволяє підсилити вплив текстового контексту на процес генерації. Під час навчання частина текстових входів із імовірністю 0.15 маскувалася, що змушувало модель одночасно вивчати як умовну, так і безумовну генерацію. На етапі

інференсу виконувалися два проходи моделі, після чого їх результати комбінувалися у вигляді лінійної інтерполяції з коефіцієнтом підсилення.

$$logits = logits_{\text{uncond}} + s \cdot (logits_{\text{cond}} - logits_{\text{uncond}})$$

Проблема інтонації та модифікація словника

Під час аналізу результатів baseline-моделі було встановлено, що вона ігнорує розділові знаки, що призводить до монотонного мовлення без пауз і інтонаційних змін. Основною причиною цього стало те, що початковий словник не містив tokenів пунктуації, а отже модель не отримувала явного сигналу для відтворення просодії.

Для перевірки цієї гіпотези було створено окрему конфігурацію моделі, в якій словник було розширено за рахунок додавання tokenів пунктуації. Проте це рішення призвело до збільшення розміру простору станів і розрідженості розподілу, що у поєднанні з незмінною ємністю моделі ускладнило процес навчання. У результаті модель не змогла ефективно засвоїти нові залежності за доступну кількість ітерацій.


Проблема зациклювання генерації та застосування евристик

Окрім проблем з інтонацією, під час тестування базової моделі та CFG Fine-tune було виявлено специфічний артефакт генерації — періодичне повторення окремих слів або фонем. Для вирішення цієї проблеми були застосовані стандартні евристичні методи регуляризації інференсу: штраф за повторення та блокування n-грам.

Отримані результати свідчать про те, що стандартні евристики декодування демонструють обмежену ефективність у задачі генерації дискретних аудіо-tokenів. На відміну від текстових моделей, де токени мають семантичну завершеність, аудіо-токени представляють низькорівневі акустичні патерни, тому втручання у розподіл ймовірностей призводить до порушення локальної узгодженості сигналу. Унаслідок цього спостерігається деградація фонетичної структури та поява артефактів, що вказує на необхідність більш глибоких змін на рівні моделі.

Узагальнені результати експериментів

FULL ANALYSIS SUMMARY: All Models & Sampling Strategies



Нижче наведено узагальнені результати оцінювання різних конфігурацій моделей та стратегій семплінгу.

Model	Sampling	CER	UTMOS	SECS
Baseline	balanced	0.329516	4.21267	0.533804
Baseline	contrastive	0.281197	4.27652	0.5713
Baseline	greedy	0.281606	4.3603	0.577627
Baseline	min_p	0.28529	4.38471	0.594845
CFG Fine-tune	cfg_balanced	0.164786	4.17695	0.5449
CFG Fine-tune	cfg_greedy	0.267194	4.13311	0.579032
CFG Learning	balanced	0.342826	4.21446	0.493807
CFG Learning	contrastive	0.320024	4.32863	0.528152
CFG Learning	greedy	0.224571	4.31453	0.538134
CFG Learning	min_p	0.294924	4.37034	0.568998

Отримані результати демонструють, що застосування Classifier-Free Guidance на етапі донавчання дозволяє суттєво покращити точність вимови, що відображається у значному зниженні CER, особливо при використанні адаптованих стратегій семплінгу (зокрема `cfg_balanced`). Водночас baseline-модель у поєднанні з сучасними методами семплінгу, такими як `contrastive` та `min_p`, демонструє конкурентні результати та забезпечує більш стабільний баланс між натуральністю звучання (UTMOS) та збереженням характеристик голосу (SECS).

Конфігурація CFG Learning, незважаючи на покращену інтонаційну виразність у окремих випадках, загалом поступається за точністю та стабільністю генерації, що підтверджує гіпотезу про недостатню ємність моделі при використанні розширеного словника. Введення нових стратегій семплінгу дозволило частково компенсувати ці обмеження, однак не усунило їх повністю.

Детальні результати експериментів

Було проаналізовано моделі та конфігурації, які продемонстрували найкращі результати у своїх групах з урахуванням нових стратегій семплінгу.

Приклад 1

Текст:

"The North Wind and the Sun were disputing which was the stronger, when a traveler came along wrapped in a warm cloak."

Даний приклад використовується для оцінки здатності моделі відтворювати довгі складні речення та підтримувати контекст.

Результат:

Найбільш стабільні результати продемонструвала CFG Learning модель, яка змогла відтворити інтонаційну структуру речення. Водночас baseline із `contrastive` та `min_p` семплінгом показав більш стабільну фонетичну точність. Інші конфігурації частіше генерували артефакти або повтори.

Приклад 2

Текст:

"He bought apples, oranges, and bananas; however, he forgot the most important thing: milk."

Даний приклад перевіряє обробку пунктуації та інтонаційних переходів.

Результат:

CFG Learning модель продемонструвала кращу інтонаційну структуру завдяки наявності пауз, однак поступалася у точності тексту. Найбільш збалансований результат показала CFG Fine-tune модель у режимі `cfg_balanced`, яка поєднала прийнятну точність із коректною інтонацією.

Приклад 3

Текст:

"Could you please tell me how to get to the nearest train station? Is it far from here?"

Даний приклад оцінює генерацію питальних конструкцій.

Результат:

Baseline-модель із min_p семплінгом показала найбільш узгоджений результат. Інші моделі або втрачали інтонаційну структуру, або демонстрували артефакти та повторення.

Приклад 4

Текст:

"The meeting is scheduled for March 15th, 2026, at 10:30 AM in room number 402."

Даний приклад перевіряє генерацію структурованої інформації.

Результат:

Жодна з моделей не продемонструвала стабільно високого результату. Найбільш прийнятні результати показали baseline (balanced) та CFG Learning (min_p), однак загалом це речення виявилось складним для всіх конфігурацій через велику кількість числових елементів.

Приклад 5

Текст:

"Stop right there! I can't believe you actually did it! That is absolutely amazing!"

Даний приклад оцінює емоційно насичене мовлення.

Результат:

CFG Learning модель із greedy семплінгом продемонструвала найбільш природну інтонацію, хоча спостерігається відхилення від тембру оригінального диктора. Загалом моделі з CFG краще передають експресивну інтонацію у подібних прикладах.

Приклад 6

Текст:

"In a hole in the ground there lived a hobbit..."

Даний приклад оцінює довгі складнопідрядні конструкції.

Результат:

Найбільш близький до природного результат показала CFG Learning модель. Baseline із сучасними семплінгами демонструє кращу точність, але поступається в інтонаційній виразності.

Приклад 7

Текст:

"Quantum entanglement is a physical phenomenon..."

Даний приклад перевіряє генерацію складної термінології.

Результат:

Baseline-модель демонструє труднощі з вимовою складних термінів. CFG-моделі значно покращують

фонетичну точність, однак у деяких випадках зберігаються повтори як артефакт авторегресії.

Приклад 8

Текст:

"Oh. I see. Well, okay then. Yes."

Даний приклад перевіряє короткі сегментовані фрази.

Результат:

Жодна модель не досягла повністю коректного результату. Baseline та CFG Fine-tune краще відтворюють текст, але неправильно розставляють паузи. CFG Learning краще передає інтонацію, однак демонструє повтори та нестабільність.

Приклад 9

Текст:

"She sells seashells by the seashore..."

Даний приклад є скоромовкою.

Результат:

Найкращий результат показала baseline-модель із balanced семплінгом. Інші конфігурації демонструють значні труднощі з фонетичною точністю.

Приклад 10

Текст:

"The city was quiet..."

Даний приклад перевіряє атмосферний описовий текст.

Результат:

CFG Learning модель продемонструвала найкращу інтонаційну виразність, хоча присутні артефакти. Інші моделі мають труднощі з коректною інтонаційною структурою.

Висновки

Отримані результати підтверджують, що застосування Classifier-Free Guidance забезпечує покращене відтворення інтонації та підвищення точності генерації мовлення. Водночас сучасні методи семплінгу, такі як contrastive та min_p, дозволяють суттєво підвищити якість baseline-моделі, що зменшує розрив між підходами.

Експерименти також показують, що використання високотемпературного семплінгу вимагає більш потужних моделей, оскільки в іншому випадку призводить до деградації фонетичної якості. Додатково виявлено, що розширення словника без відповідного збільшення ємності моделі призводить до нестабільності генерації та появи некоректних інтонаційних пауз.

У цілому, результати свідчать про те, що подальше покращення якості TTS у даному підході потребує збільшення ємності моделі та більш узгодженого поєднання архітектурних рішень із методами семплінгу.